

MEXICAN ASTROCOSMO STATISTICS SCHOOL
LISTA DE EJERCICIOS DEL TALLER DE ESTADÍSTICA BAYESIANA

Instructor: Mario Carranza

Lunes, 10 de junio de 2019.

Ejercicios

1. Para los siguientes modelos identifique las distribuciones posteriores basadas en una muestra aleatoria de tamaño n . Muestre que se tratan de previas conjugadas y explícite/ verifique la actualización de los hiperparámetros.

Distribución Gama Inversa: Si $X \sim \text{Gama}(a, b)$ entonces $1/X \sim \text{GamaInv}(a, b)$.

La función de densidad de una gama inversa es

$$p(\theta; a, b) = \frac{b^a}{\Gamma(a)} \theta^{-(a+1)} \exp\left(-\frac{b}{\theta}\right)$$

a)

$$\begin{aligned} \text{Beta}(a, b) &\xrightarrow{\theta} \text{Geom}(\theta) \\ \theta|\vec{x} &\sim \text{Beta}\left(a + n, b + \sum x_i\right) \end{aligned}$$

b)

$$\begin{aligned} \text{Beta}(a, b) &\xrightarrow{\theta} \text{Binom}(m, \theta) \\ \theta|\vec{x} &\sim \text{Beta}\left(a + \sum x_i, b + mn - \sum x_i\right) \end{aligned}$$

c)

$$\begin{aligned} \text{Beta}(a, b) &\xrightarrow{\theta} \text{Bern}(\theta) \\ \theta|\vec{x} &\sim \text{Beta}\left(a + \sum x_i, b + n - \sum x_i\right) \\ \theta|\vec{x} &\sim \text{GamaInv}\left(a + n, b + \sum x_i\right) \end{aligned}$$

d)

$$\begin{aligned} \text{GamaInv}(a, b) &\xrightarrow{\theta} \text{Gama}(\alpha, \theta) \\ \theta|\vec{x} &\sim \text{GamaInv}\left(a + n\alpha, b + \sum x_i\right) \end{aligned}$$

e)

$$\begin{aligned} \text{GamaInv}(a, b) &\xrightarrow{\theta} \text{Normal}(\mu, \theta) \\ \theta|\vec{x} &\sim \text{GamaInv}\left(a + \frac{n}{2}, b + \frac{1}{2} \sum (x_i - \mu)^2\right) \end{aligned}$$

f)

$$\begin{aligned} \text{Normal}(\mu_0, \theta_0) &\xrightarrow{\mu} \text{Normal}(\mu, \theta) \\ \mu|\vec{x} &\sim \text{Normal}\left(\frac{\frac{\sum x_i}{\theta} + \frac{\mu_0}{\theta_0}}{\frac{n}{1} + \frac{\theta}{\theta_0}}, \frac{1}{\frac{n}{1} + \frac{\theta}{\theta_0}}\right) \end{aligned}$$

g)

$$\begin{aligned} \text{Gama}(a, b) &\xrightarrow{\theta} \text{GamaInv}(\alpha, \theta) \\ \theta|\vec{x} &\sim \text{Gama}\left(a + n\alpha, \frac{1}{b} + \sum \frac{1}{x_i}\right) \end{aligned}$$

h)

$$\begin{aligned} \text{Gama}(a, b) &\xrightarrow{\alpha} \text{Pareto}(\alpha, \theta) \\ \theta|\vec{x} &\sim \text{Gama}\left(a + n, \frac{b}{1 + b(\sum \log x_i - n \log \theta)}\right) \end{aligned}$$

2. Sea X_1, \dots, X_n una muestra aleatoria con $X_i \sim \text{Beta}(\theta)$. Supongamos una previa para θ tal que $\theta \sim \text{Beta}(\alpha, \beta)$. Obtenga la predictiva posterior para X_{n+1} . No se preocupe si no logra identificar de que distribución se trata.
3. Supongamos que queremos obtener el estimador óptimo Bayesiano con una función de pérdida $L(a, \theta) = (a - \theta)^2$. Demuestre que el valor a^* que minimiza la función $E[(a - \theta)^2]$ es $a^* = E[\theta]$.
4. Obtenga la previa objetiva bajo el criterio de Jeffreys para el modelo Exponencial(λ).
5. Obtenga la forma del factor de Bayes cuando contamos con una muestra $X_1, \dots, X_n \sim \text{Bern}(\theta)$ con una previa $\text{Beta}(\alpha, \beta)$ y queremos contrastar las hipótesis

$$H_0 : \theta \leq 0.5 \text{ vs. } H_0 : \theta > 0.5.$$

6. ¿Qué puede decir del algoritmo Metropolis-Hastings cuando $Q(\theta|\theta^*) = Q(\theta)$, es decir, no depende del estado actual?
7. ¿Qué puede decir del algoritmo Metropolis-Hastings cuando $Q(\theta|\theta^*) = Q(\theta^*|\theta)$, es decir, Q es simétrica?
8. Supongamos que usted quiere obtener observaciones simuladas de una normal bivariada con vector de medias $\boldsymbol{\mu} = (\mu_1, \mu_2)$ y matriz de covarianzas

$$\boldsymbol{\Sigma} = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{12} & \Sigma_{22} \end{bmatrix}.$$

Suponga que sólo sabe simular de normales univariadas $N(\mu, \sigma^2)$. Implemente un Muestreador de Gibbs para simular de esta normal bivariada. Pista: Use el conocimiento que existe de las condicionales de las normales multivariadas.

9. Recordemos que la función de probabilidad de una Binomial Negativa es

$$P(x|\lambda, m) = \binom{m+x-1}{x} \lambda^x (1-\lambda)^m$$

Suponga se cuenta con una muestra aleatoria X_1, \dots, X_n de la distribución Binomial-Negativa($x|\lambda, m$), con $0 < \lambda < 1$ (desconocida) y m conocida. La inicial de λ es

$$p(\lambda) \propto \lambda^{-1}(1-\lambda)^{-1}$$

La distribución Binomial-Negativa se puede expresar como una distribución marginal de la distribución Poisson-Gamma.

$$P_{\text{Bin-Neg}}(x|\lambda, m) = \int_0^\infty P_{\text{Poisson}}(x|\theta) P_{\text{Gamma}}\left(\theta\left|m, \frac{1-\lambda}{\lambda}\right.\right) d\theta.$$

Podemos plantear este problema de inferencia como un modelo jerárquico de tres niveles.

Nivel I. (Observaciones)

$$X_i|\theta_i \sim \text{Poisson}(\theta_i) \text{ con } X_i \perp\!\!\!\perp X_j \text{ si } i \neq j.$$

Nivel II. (Parámetros)

$$\Theta_i|m, \lambda \sim \text{Gamma}\left(m, \frac{1-\lambda}{\lambda}\right) \text{ con } \Theta_i \perp\!\!\!\perp \Theta_j \text{ si } i \neq j.$$

Nivel III. (Hiperparámetros)

$$p(\lambda) \propto \lambda^{-1}(1-\lambda)^{-1}$$

Implemente el algoritmo de muestreador de Gibbs para simular tanto λ como de cada Θ_i . Note que el algoritmo debe tener $n+1$ pasos pero n de ellos son muy similares.

Pregunta adicional: ¿Qué pasaría si m es también desconocida? Si ya tenemos el algoritmo para m conocida, ¿basta agregar un paso más al algoritmo?

Referencias

1. Bernardo J, Smith A (2000). Bayesian Theory. John Wiley & Sons, West Sussex, England.
2. Gelman A, Carlin J, Stern H, Rubin D (2004). Bayesian Data Analysis. 2nd edition. Chapman & Hall, Boca Raton, FL.
3. George Casella & Edward I. George (1992) Explaining the Gibbs Sampler, The American Statistician, 46:3, 167-174